Systemidentifikation eines inversen Pendels

Ali Bibi, Oussema Dhaouadi, Rachid Ellouze Mat.nr. 03677539 - 03678727 - 03671114 Technische Universität München, Deutschland {ali.bibi, oussema.dhaouadi, rachid.ellouze}@tum.de

Zusammenfassung—Motiviert von der hoch entwickelten Steuerungssystemen im Bereich Robotik und Automatisierung wird ein inverses Pendel vorgestellt. Die Identifikation des inversen Pendels in einem komplexen System ist auf Grund der Nichtlinearität und der Dynamik sehr schwierig. Für die Zwecke der Erklärung der Identifikation eines nichtlinearen dynamischen Systems wird auf ein einfaches inverses Pendel beschränkt. Ein trainiertes neuronales Netzwerk zeigt eine erfolgreiche Modellierung des Systems, das alle komplexe interne Elemente des echten Systems annähert.

I. REELLES SYSTEM - MODELLBILDUNG [Ag.1]

A. Systembeschreibung [Ag.1-a]

Ein umgekehrtes Pendel ist eines, bei dem sich der Massenmittelpunkt über seinem Drehpunkt befindet, d.h. wo die Schwerkraft zeigt. Das Hauptziel ist es, das Gleichgewicht bei allen Geschwindigkeiten aufrecht zu erhalten, ohne dass der Benutzer eingreifen muss. Es handelt sich somit um ein geregeltes System, was gegenüber externen unterschiedlichen Störungen unempfindlich, robust und stabil ist.

Eine zweidimensionale Version des inversen Pendelsystems mit einem Wagen wird betrachtet, bei dem das Pendel dazu gezwungen ist, sich in der in der vertikalen Ebene zu bewegen. Bei diesem System ist die Steuereingabe die Kraft \vec{F} , die den Wagen durch ein Motor horizontal bewegt, und die Ausgaben sind die Winkelposition des Pendels θ und die horizontale Position des Wagens x. Es wird ausschließlich die Winkelposition $y=\theta$ identifiziert, die das System nimmt, nachdem der Wagen mit einer externen Impulskraft $u=\vec{F}_{ext}$ gestoßen wird. (Abb. 1) Nachdem bei der differentialen Gleichung des dynamischen

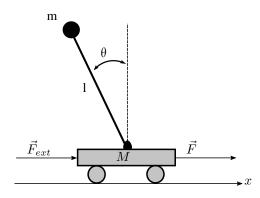


Abbildung 1. Ein inverses Pendelsystem

Systems Nichtlinearitäten auftauchen, ist seine Identifikation von Vorteil.

B. Anwendungen [Ag.1-b]

Die zahlreichen praktischen Anwendungen des umgekehrten Pendels sind in verschiedenen Bereichen interessant und wichtig. In der Robotik sind hochmoderne Systeme mit umgekehrten Pendeln entwickelt. Diese finden Anwendung im Transport Maschinen, die Objekte ausgleichen müssen oder bei Robotern, die im Haushalt und in der Industrie verwendet werden. Eine berühmteste Anwendung des umgekehrten Pendels ist das Segway (Abb. 2).



Abbildung 2. Der Segway Personal Transporter¹

C. Realisierung in Simulink [Ag.1-c]

Das Pendelmodell wird mithilfe der physikalischen Modellierungsblöcke der Simscape-Erweiterung für Simulink erstellt. Die Blöcke in der Simscape-Bibliothek stellen tatsächliche physikalische Komponenten dar. Daher können komplexe dynamische Mehrkörpermodelle erstellt werden, ohne dass mathematische Gleichungen (evtl. schwer darstellbar) auf der Grundlage physikalischer Prinzipien erstellt werden müssen. Abbildung 3 zeigt das physikalische Model, das das echte geregelte System darstellt. Die physikalischen Größen, die das echte System definieren, sind in der Tabelle I zusammengefasst. Das mit unterschiedlichen Signalen (harmonische Schwingung, Sprungsignal) eingespeiste System zeigt ein stabiles Verhalten der Dynamiken θ und x. Es werden nur die Ausgangsdaten des Winkels θ betrachtet. Das Model ist nun bereit für die Generierung der für die Identifikation notwendigen Messdaten.

II. BLACKBOX MODELLIERUNG MIT NEURONALEM NETZ $_{[Ag,2]}$

Da der Signalfluss $\vec{F}_{ext} o \theta$ von nichtlinearen dynamischen Komponenten verarbeitet wird, bildet das System eine

¹Quelle: https://shop.segway.com/de-de/11/-ninebot-by-segway-one-e

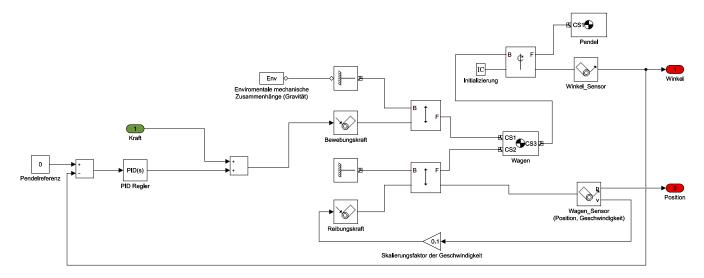


Abbildung 3. Ein physikalisches Modell eines inversen Pendels

Tabelle I Eigenschaften des zu identifizierenden Systems

Größe	Bedeutung	Wert - Einheit
M	Masse des Wagens	0,5kg
m	Masse des Pendels	0,2kg
M	Reibung des Wagens	$0,1 Nm^{-1}s$
l	Lenge des Pendels	0,3 m
J	Trägheit des Pendels	$0,006 kg.m^2$
$ec{F}$	Bewegungskraft durch Drehung des Motors	N
\vec{F}_{ext}	Externe störende Kraft	N
x	Position des Wagens	m
$J\theta$	Winkel des Pendels zur Vertikale	rad

nichtlineare zeitabhängige Abbildung, die identifiziert wird. Als neuronale Netze durch ihre zahlreiche Parameter eine beliebig komplexe Funktion darstellen können, wird hierfür ein GDNN (General Dynamic Neural Network) verwendet. GDNNs sind von Besonderheit, denn sie können nicht nur nichtlineare Funktionen sondern auch die Dynamik des Systems (Systemzustände) lernen.

A. Netzwerkstruktur [Ag.2-a]

Die gewählte Netzwerkstruktur ist das General Dynamic Neural Network (GDNN), da dies eine volle Freiheitsgrad bietet, um das dynamische Verhalten vollständig zu beschreiben. Es handelt sich um ein GDNN mit 2 versteckten Schichten, die jeweils 4, 3 Neuronen enthalten. Die zu lernende Abbildung ist eine skalare Funktion, was jeweils 1 Neuron für die Eingangs- und Ausgangsschichten entspricht. Alle Neuronen werden mit einer Nichtlinearität aktiviert, um die nichtlineare Abbildung möglichst-nah annähernd zu repräsentieren. Die Entscheidung für eine solche Modellgröße ist darum getroffen, um die Komplexität des Systems genauer zu beschreiben und sehr längere Trainingszeiten und Overfitting zu vermeiden. Zwischen den Schichten wurden verzögerte Rückkopplungen

eingebaut, damit das neuronale Netzwerk die Dynamik lernen kann.

B. Realisierung in Matlab / Simulink [Ag.2-b]

III. ANREGUNGSSIGNAL UND SYSTEMIDENTIFIKATIONSPROZESS [Ag.3]

A. Anregungssignal [Ag.3-a-b]

Das Modell wurde mit einem amplitudenmodulierten Pseudo-RauschBinär-Signal (APRBS) angeregt, um möglichst alle Frequenzen und Amplituden abzudecken. Die Abbildung 5 zeigt ein erzeugendes APRBS signal.

B. Systemidentifikationsprozess [Ag.3-c]

Abbildung 4 zeigt das allgemeine Blockschaltbild des Identifikationssystems.

IV. TRAINIEREN VOM NEURONALEN NETZWERK [Ag.4]

- A. Trainieren [Ag.4-a]
- B. Beobachtungen [Ag.4-b]

Während der ersten Iterationen des Trainings ist der Fehler sehr groß und der Ausgangssignal des Modells und der Ausgangssignal des echten Systems stimmen nicht überein. Im Laufe der Zeit lernt das Modell das System besser und damit sinkt der Fehler und die beiden Ausgangssignale nähren sich. Die Zufriedenheit ist erreicht.

C. Validierung [Ag.4-c]

Um die Validität des Systems zu überprüfen, wird dem Modell nach der Trainingsphase ein anderes Eingangssignal (auch ein APRBS) eingespeist. Die beiden Ausgangssingle sind ähnlich und sehr nah zueinander. Jedoch stellt sich kleiner konstanter Fehler nach einigen Iterationen ein. Die Ursache des Fehlers liegt an dem globalen Integrationsverhalten des Systems. In den alle ersten Iterationen (Einschwingungsphase) ist der Fehler relativ groß, das liegt daran, dass das Modell das System nur in Steady-State gelernt hat. Somit ist das Modell valid.

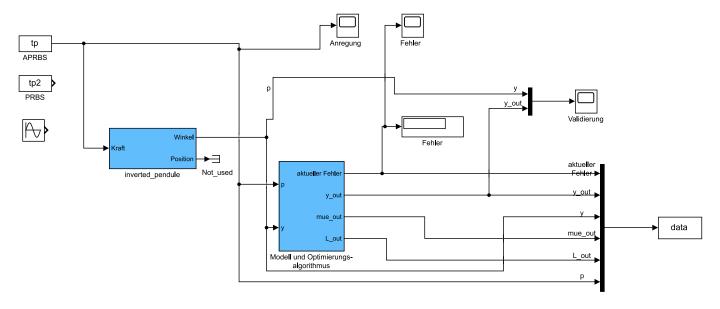


Abbildung 4. Identifikation eines inversen Pendels

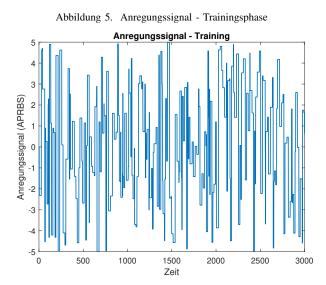
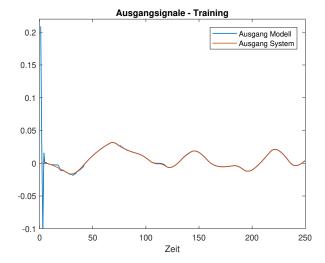


Abbildung 6. Ansgangssystem / Ansgangsmodell - Trainingsphase



V. EXPERIMENTE [Ag.5]

A. Veränderung der Modellstuktur [Ag.5-a]

Zwei Möglichkeiten bestehen für die Änderung der Modellstruktur. Zunächst wird die Anzahl der Neuronen geändert. Für eine geringere Anzahl aller Neuronen wird das Modell schwach, um die Komplexität des System zu lernen. Hingegen das Erhöhung dieser Anzahl zeigt ein erfolgreiches Trainieren, jedoch die Validierung scheitert, da diese Neuronen zusätzliche Rauschen lernen werden. Die zweite Möglichkeit besteht daran, dass die Anzahl der Schichten verändert wird. Das Einfügen von mehreren Schichten zeigt ein Overfitting. Dies liegt daran, dass das Model auch zusätzliche nicht relevante Merkmale lernen kann.

B. Veränderung des Anregungssignal [Ag.5-b]

Auch, wenn das trainierte Modell mit anderen Eingangssignale angeregt wird, liefert es Ausgänge, die sehr nah an der Ausgänge des echten Systems. Somit hat das gebaute Netzwerk eine Verallgemeinerung des Systems. Jedoch liegt ein sehr geringes Bias wegen allgemeinen Integrationsverhalten.

C. Statisches Modell [Ag.5-c]

Die Modellierung mit einem statischen Modell scheitert auf Grund der fehlenden Darstellung der Dynamik im System. Das Modell lernt eine Art von Mittelwerten, was die Forderungen nicht erfüllen.

VI. FAZIT

Neuronale Netzwerke sind geeignet für die Systemidentifikation des inversen Pendels. Eine besondere Wahl der Benut-

Abbildung 7. Kostenfunktion - Trainingsphase

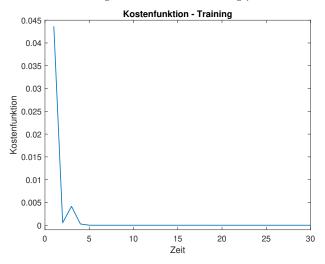


Abbildung 8. Ansgangssystem / Ansgangsmodell - Validierungsphase

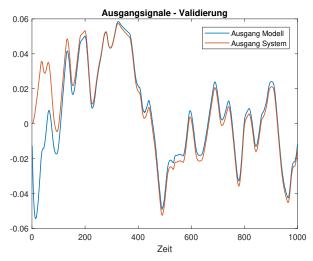


Abbildung 9. Kostenfunktion - Validierungsphase

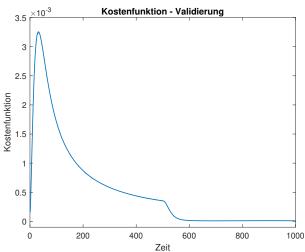
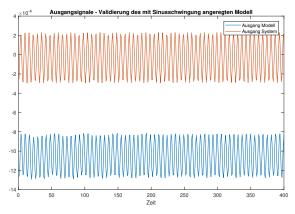


Abbildung 10. Ansgangssystem / Ansgangsmodell - Validierungsphase des mit Sinusschwingung angeregten Modell



zerparameter sind notwendig für eine gute Modellierung. Dank seiner Verzögerungseinheiten (TDLs) ist ein GDNN dazu fähig, eine sehr gute eine Annäherung von einem dynamischen System zu lernen.

LITERATUR

[1] Christian Endisch, "Systemidentifikation in der Mechatronik", Technische Hochschule Ingolstadt 2013.